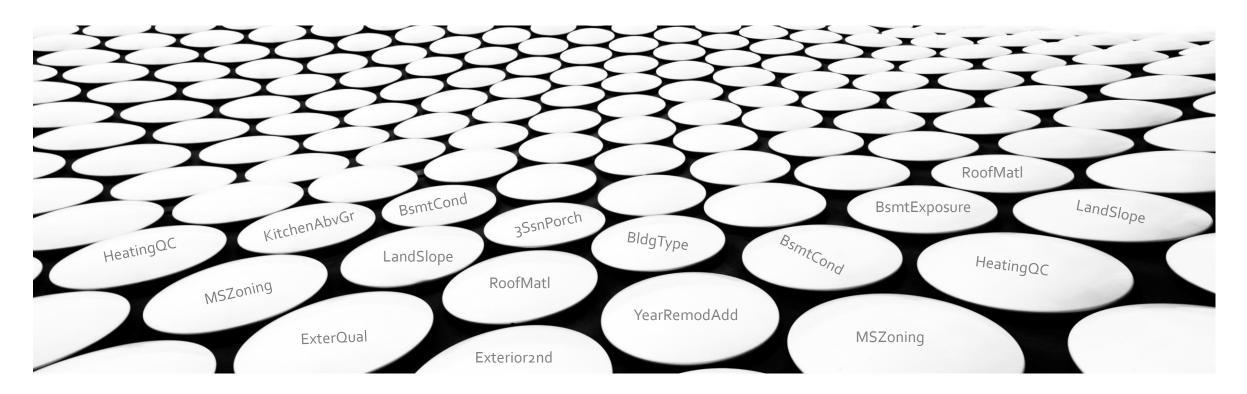
ПРОЕКТПРЕДСКАЗАНИЕ ЦЕН НА НЕДВИЖИМОСТЬ

ГАЛИНА ГОРЯИНОВА & АНДРЕЙ АБРАМОВ



ОСНОВНЫЕ ШАГИ И ВЫРАБОТКА СТРАТЕГИИ

Оставить как есть и их использов ать Почистить данные?

Отобрать наиболее важные и «живые» Почитать описание к массиву данных

Собрать ис пакет да предварител обработки массив, готовый д.

Какие модели использова ть? анализ Единичные модели или моделиров собирать ния

Сколько времени потратить чтобы на во хватило?

Получение исходных данных

Анализ внутренней структуры данных (разведочный анализ)

Заполнение пропусков и чистка

данные на

обучение и

Подготовка сценариев моделирования

Выполнение подготовленно го кода и подача

Получение исходных данных прошло очень гладко. Пожалуй наиболее беспроблемный шаг

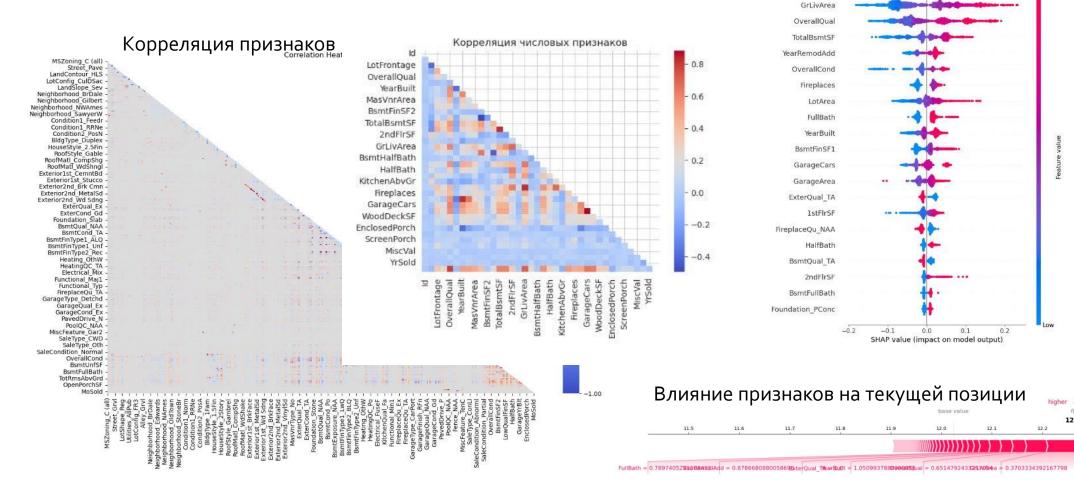
Признаков в исходных данных достаточно много ~8о. Отобрать какието наиболее важные или не важные и не испортить модель оказалось достаточно трудной задачей

Шаг, на который пришлось потратить ~80% имеющегося времени. Сильную поддержку дало описание всех столбцов с возможными вариантами категориальных признаков.

Хорошо что был подготовленный заранее шаблон, который удалось быстро привести в готовность

Наиболее приятный момент – когда вот, вот «стрельнет»!

ВАЖНОСТЬ ПРИЗНАКОВ



f(x)12.27

0.2

Влияние наиболее важных

числовых признаков

ПРОМЕЖУТОЧНЫЕ ПАРАМЕТРЫ МОДЕЛЕЙ

Этап 2 Обучения: Применение группы моделей к результатам работы моделей предыдущего этапа

Этап 2 Тестирования: Применение группы моделей к результатам работы моделей предыдущего этапа

middle metrics mse LinearRegression 0.008769 Ridge 0.009481 Lasso 0.048565 ElasticNet 0.033684 LassoLars 0.048564 BayesianRidge 0.012629 ARDRegression 0.009761 TweedieRegressor 0.014967 10 CatBoostRegressor 0.001688 11 XGBRegressor 0.000052 21 STEP-2: LinearRegression 0.000045 STEP-2: Ridge 0.000097 STEP-2: Lasso 0.063309 24 STEP-2: Lars 0.000052 25 STEP-2: ElasticNet 0.023572 26 27 STEP-2: LassoLars 0.063309 STEP-2: BayesianRidge 0.000045 STEP-2: ARDRegression 0.000045 STEP-2: TweedieRegressor 0.019317 30 STEP-2: CatBoostRegressor 0.000575 31 STEP-2: XGBRegressor 0.000021 40 STEP-1v: LinearRegression valid 0.016319 41 STEP-1v: Ridge valid 0.014796 42 STEP-1v: Lasso valid 0.049560 STEP-1v: Lars valid 0.046427 STEP-1v: ElasticNet valid 0.032423 STEP-1v: LassoLars valid 0.049559 STEP-1v: BayesianRidge valid 0.015413 STEP-1v: ARDRegression valid 0.013026 STEP-1v: TweedieRegressor valid 0.016108 STEP-1v: CatBoostRegressor valid 0.030039 STEP-1v: XGBRegressor valid 0.019299 60 STEP-2v: LinearRegression valid 61 STEP-2v: Ridge valid 0.018252 62 STEP-2v: Lasso valid 63 STEP-2v: Lars valid 0.01997 64 STEP-2v: ElasticNet valid 0.034 STEP-2v: LassoLars valid 0.077 66 STEP-2v: BayesianRidge valid 0.01976 STEP-2v: ARDRegression valid 0.019712 STEP-2v: TweedieRegressor valid 0.026051 STEP-2v: CatBoostRegressor valid 0.017672

Этап 1 Обучения: Применение группы моделей к исходным данным

Этап 1 Тестирования: Применение группы моделей первого этапа обучения

Решение какую модель лучше давать в качестве финальной при подаче

kaggle

ВЫПОЛНЕННЫЕ ПОДАЧИ

#	Ансамбль	Основная модель	Kaggle Score	Kaggle position
1	Stacking	XGBoost Regr. (Step-2)	0.14716	2337
2	Stacking	Liner Regr. (Step-2)	0.20205	-
3	-	CatBoost Regr. (Step-1)	0.14415	2031-2
4	Stacking	CatBoost Regr. (Step-2)	0.17397	-
5	Stacking	ARDRegression (Step-2)	0.20205	-
6	Stacking	Lasso (Step-2) (с изменением одного из параметров очистки)	0.30209	-
7	Stacking	BayesianRidge (Step-2)	0.20205	-

